

关于梯度下降的算法原理.

我们可以从之前的求 $\min\{\dots\}$ 的最小值来说. 在 CS229 中, 我们之前使用的 $L(w)$ 被称为 \min 函数. 也就是对我们来说, 我们可以重新定义.

对于一个线性模型

$$h_w(x) = w^T x + b \quad (d+1 \text{ 为 } w \text{ 的维度} + 1)$$

我们令 $J(w) = \frac{1}{d+1} \sum_{i=1}^m (h_w(x^{(i)}) - y^{(i)})^2$

那么, $\min\{J(w)\}$ J 是关于 w 的函数

求 J 的最小值, 我们就可以得到 w 的最优解

之前, 我们发现可以通过其它方法计算

但是 今天我们将采用更加通用的方法过
解. 梯度下降 [Gradient Descent]

所以听到 GD 的时候,它确实有时在说
梯度下降 [梯度下降]

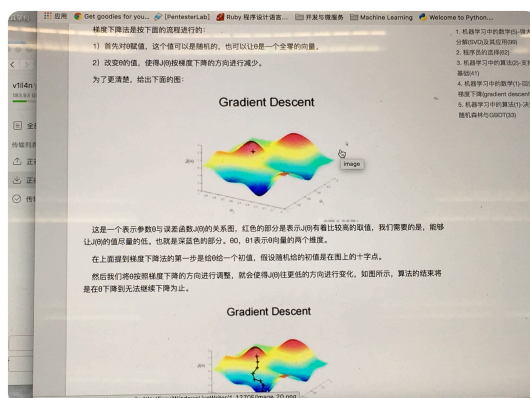
好的. 我们开始.

$J(w)$ 函数我们称之为 成本函数
Cost Function

$J(w)$ 必须可微

$\Delta J(w)$ 表示 w 处的微分

PS: Cost Function 这个翻译怪怪的
但是 Cost 这个词一定要记住



基本步骤.

① 对 w 赋值 [初始值]

② 对成本函数 $J(w)$ 进行微分运算

$$\Delta(w) = \frac{\partial J(w)}{\partial w}$$

$\Delta(w)$ 的方向为正. 表上升

$\Delta(w)$ 的方向为负. 表下降

③ 选择方向. [梯度向下. 为负]

确定学习率 α (Step). 乘以学习率 (步长)

$$w = w - \alpha \Delta(w) \Rightarrow \text{更新 } w$$

④ 继续学习....

关于 GD 的算法: BGD SGD 与 MBGD